

1. Oggetto del progetto

Il presente progetto ha l'obiettivo di sperimentare l'uso comparativo di diverse tecnologie per l'analisi di big data su un dataset reale di dimensione significativa, con particolare attenzione agli aspetti di: (i) progettazione delle elaborazioni, (ii) preparazione e pulizia dei dati, (iii) confronto tra diverse tecnologie di analisi e (iv) efficienza e scalabilità delle soluzioni realizzate.

A tal fine, si consideri il dataset Flight Delay Dataset del 2024 disponibile su Kaggle¹, che contiene oltre 7 milioni di record e 35 colonne in formato CSV, con informazioni relative a voli, ritardi, cancellazioni, deviazioni, aeroporti, compagnie aeree e altri attributi operativi.

2. Tecnologie da utilizzare

Dopo avere preparato opportunamente il dataset, progettare e realizzare almeno due delle analisi descritte nella Sezione 3 utilizzando almeno tre tra le seguenti tecnologie: MapReduce, Hive, Spark Core e Spark SQL.

3. Analisi da realizzare

3.1 Statistiche delle compagnie aeree

Realizzare un job in grado di generare le statistiche di ciascuna compagnia aerea presente nel dataset, indicando, per ogni compagnia: (a) il nome o codice della compagnia; (b) una lista di aeroporti di partenza o tratte servite dalla compagnia, indicando per ciascuno di essi: (i) il numero di voli presenti nel dataset; (ii) il ritardo minimo, massimo e medio in arrivo; (iii) il tasso di cancellazione dei voli; e (iv) l'elenco dei mesi in cui quella compagnia opera su quell'aeroporto o tratta.

3.2 Report dei ritardi per aeroporto e periodo temporale

Realizzare un job in grado di generare un report contenente, per ciascun aeroporto di partenza e per ciascun mese: (a) il numero di voli appartenenti a tre fasce di ritardo in partenza: (i) basso: meno di 15 minuti (ii) medio: tra 15 e 60 minuti e (iii) alto: oltre 60 minuti, (b) per ciascuna fascia, il ritardo medio in partenza e il ritardo medio in arrivo e (c) le tre cause di cancellazione o ritardo più frequenti, se disponibili nel dataset.

3.3 Ranking delle coppie compagnia-aeroporto con comportamento anomalo nei ritardi

Realizzare un job in grado di generare, per ciascun aeroporto di partenza e per ciascuna compagnia aerea, un report di performance che confronti il comportamento della compagnia in quell'aeroporto con il comportamento medio di tutte le compagnie che operano nello stesso aeroporto. Per ciascuna coppia (aeroporto di partenza, compagnia), il report deve contenere: (a) il numero di voli operati da quella compagnia in quell'aeroporto; (b) il ritardo medio in partenza e il ritardo medio in arrivo; (c) il tasso di cancellazione; (d) la differenza tra il ritardo medio in partenza della compagnia e il ritardo medio in partenza complessivo di quell'aeroporto; (e) la posizione in classifica della compagnia in quell'aeroporto in base al ritardo medio in partenza, dalla migliore alla peggiore.

4. Preparazione dei dati

Prima di procedere con le analisi, il dataset dovrà essere opportunamente preparato. A titolo esemplificativo, potranno essere effettuate operazioni di: eliminazione di record errati, incompleti o non significativi; normalizzazione dei valori degli attributi utilizzati; selezione delle colonne rilevanti ai fini delle analisi; eventuale

¹ <https://www.kaggle.com/datasets/hrishitpatil/flight-data-2024>

trasformazione di attributi temporali o categorici. Le operazioni effettuate dovranno essere chiaramente descritte e motivate nel rapporto finale.

5. Rapporto finale

Per ciascun job realizzato, il rapporto finale dovrà contenere almeno i seguenti elementi:

- descrizione delle operazioni di preparazione dei dati eventualmente effettuate;
- descrizione delle scelte implementative adottate per ciascuna tecnologia selezionata, in forma testuale e/o tramite pseudocodice;
- prime 10 righe dei risultati prodotti dai vari job;
- tabelle e grafici di confronto dei tempi di esecuzione in locale e su cluster, al variare della dimensione dell'input e, se possibile, della dimensione del cluster;
- commento critico ai risultati ottenuti, con particolare attenzione a: (i) espressività delle tecnologie utilizzate, (ii) semplicità implementativa; (iii) efficienza; (iv) scalabilità; (iv) impatto delle operazioni di shuffle, aggregazione e preparazione dei dati;
- link a un repository GitHub contenente il codice completo delle soluzioni.

6. Indicazioni per l'analisi sperimentale

Ai fini dello studio di efficienza e scalabilità, si suggerisce di generare dataset di dimensione crescente:

- utilizzando porzioni del file originale per le dimensioni minori;
- utilizzando copie o repliche controllate del dataset per le dimensioni maggiori.

Le modalità adottate dovranno essere esplicitate nel rapporto finale.

Si raccomanda inoltre di eseguire, quando possibile, le prove in ambiente locale e su cluster in modo da evidenziare il comportamento delle diverse tecnologie al variare del contesto esecutivo.

7. Materiale da consegnare

La consegna dovrà comprendere:

- un rapporto finale in formato PDF;
- un repository GitHub contenente:
 - codice sorgente;
 - script di esecuzione;
 - eventuale documentazione aggiuntiva;
 - istruzioni essenziali per la riproducibilità delle soluzioni.

8. Criteri generali di valutazione

La valutazione terrà conto dei seguenti aspetti:

- correttezza e completezza delle analisi richieste;
- qualità delle scelte progettuali e implementative;
- chiarezza e qualità del rapporto finale;
- accuratezza dell'analisi sperimentale;
- qualità del confronto tra le tecnologie utilizzate;
- grado di riproducibilità delle soluzioni proposte.

9. Note finali

Tutte le specifiche non esplicitamente definite nel presente documento possono essere scelte liberamente dagli studenti, purché tali scelte risultino motivate, coerenti con gli obiettivi del progetto e chiaramente documentate.